

Sistema de Análise Inteligente de Dados de E-commerce com Agentes de IA

Leonardo da Silva Oliveira¹, Natan Rodrigues Martins²

¹Pós Graduação de Ciência de dados e Machine Learning - Universidade de Rio Verde (UniRV)
Rio Verde - GO, 75901-970

Resumo. *Este trabalho apresenta o desenvolvimento e avaliação do Commerce Intelligence, um sistema de análise de dados de e-commerce baseado em uma arquitetura multi-agentes de Inteligência Artificial. O sistema implementa um pipeline de agentes especializados que processam consultas em linguagem natural, realizam análises complexas de dados e fornecem respostas contextualizadas em português. A arquitetura integra modelos de linguagem de grande escala (LLMs) com banco de dados PostgreSQL e protocolo MCP (Model Context Protocol) para acesso a ferramentas externas. Resultados experimentais demonstram que o sistema alcança 73% de acurácia média na interpretação de consultas, com capacidade de gerar e executar queries SQL automaticamente e fornecer respostas estruturadas com alto grau de confiança.*

1. Introdução

A análise de dados em plataformas de e-commerce tem se tornado cada vez mais complexa devido ao volume crescente de informações e à necessidade de insights acionáveis em tempo real. Sistemas tradicionais de Business Intelligence (BI) exigem conhecimento técnico especializado para elaboração de consultas e interpretação de resultados, criando uma barreira entre os dados e os usuários finais.

Este trabalho apresenta o Commerce Intelligence, um sistema que permite a usuários não-técnicos realizar análises complexas de dados de e-commerce através de perguntas em linguagem natural. O sistema utiliza uma arquitetura inovadora baseada em agentes especializados que colaboram para interpretar consultas, gerar SQL automaticamente, executar análises e fornecer respostas contextualizadas.

1.1. Objetivos

Os principais objetivos concentram-se no desenvolvimento de uma arquitetura modular de agentes de IA voltada para a análise de dados, visando a implementação de consultas de dados a partir de linguagem natural. Além disso, o projeto busca integrar diversas fontes de dados, abrangendo desde bases internas e até recursos externos via MCP.

2. Arquitetura do Sistema

2.1. Visão Geral

O Commerce Intelligence implementa uma arquitetura baseada em microserviços com três camadas principais:

- **Camada de APIs de entrada:** Desenvolvida com Elysia.js e Bun runtime, oferece endpoints RESTful documentados via Swagger/OpenAPI.

- **Camada de Orquestração:** Coordena o pipeline de agentes e gerencia o fluxo de dados.
- **Camada de APIs internas:** Serviço em Python (FastAPI) responsável pela execução de modelo de previsão de vendas.
- **Camada de Infraestrutura:** Gerencia conexões com PostgreSQL, serviços de IA (ADK) e servidores MCP.

2.2. Pipeline de Agentes

O pipeline de agentes do sistema é estruturado através de agentes especializados que trabalham de forma coordenada para processar as solicitações do usuário. Tudo começa com o Agente Interpreter, que utiliza prompt engineering para analisar a intenção do usuário a partir de queries em linguagem natural, extraindo entidades, flags e scores de confiança.

Na sequência, o fluxo pode seguir por diferentes caminhos dependendo da necessidade: o Agente Category Lookup realiza a validação de categorias para previsões utilizando matching determinístico e fuzzy, enquanto o Agente Predict aciona uma API interna em Python (FastAPI/PyCaret) para gerar previsões de vendas baseadas na categoria e no horizonte temporal solicitado. Condicionalmente, o Agente Data Query é responsável pela geração e execução segura de SQL via few-shot learning, contando com camadas de proteção contra SQL injection e whitelist de operações.

Para a finalização da entrega, o Agente Responder consolida os resultados das queries, previsões e dados MCP em uma resposta textual em português através de template-based prompting. O Agente Suggestion entra em cena para gerar três sugestões de follow-up contextuais, e, por fim, o Agente Enhancer realiza o refinamento final e a adição de metadados, entregando uma resposta completa que inclui fontes, níveis de confiança e sugestões de continuidade.

2.3. Fluxo de Dados

Cada agente enriquece o contexto, que é passado para o próximo agente na cadeia. Agentes são executados condicionalmente baseados na interpretação.




Figura 1. Diagrama de fluxo de dados

2.4. Banco de Dados

O sistema utiliza o dataset Olist Brazilian E-commerce, que é estruturado em oito tabelas principais. O conjunto de dados abrange 32.951 produtos ofertados por 3.095 vendedores para uma base de 99.441 clientes, totalizando o mesmo número de pedidos realizados. Além disso, o sistema processa 112.650 itens de pedidos, 103.886 registros de pagamentos e 99.224 avaliações, sendo tudo isso complementado por uma tabela de geolocalização que contém mais de 1 milhão de entradas.

2.5. Modelo de Machine Learning

2.5.1. Formulação do Problema

O problema foi modelado como uma tarefa de regressão supervisionada, cujo objetivo é prever o valor total de vendas futuras por categoria de produto, considerando séries temporais mensais extraídas do dataset. A previsão é realizada para horizontes futuros de até N meses, permitindo análises de curto e médio prazo para suporte à tomada de decisão.

2.5.2. Preparação dos Dados

Na etapa de preparação dos dados para o treinamento do modelo foram realizadas as seguintes operações:

- filtragem de pedidos com status delivered
- agregação das vendas por mês e categoria de produto
- tratamento de valores ausentes e remoção de registros inconsistentes
- criação de séries temporais mensais por categoria de produto
- padronização da estrutura temporal, garantindo a existência de registros para todos os meses, inclusive aqueles sem vendas

2.5.3. Modelagem

Foi utilizada a biblioteca PyCaret, que oferece uma abordagem de AutoML, permitindo a avaliação automática de múltiplos modelos de regressão sob o mesmo conjunto de dados e métricas padronizadas. Essa abordagem foi escolhida por facilitar a comparação objetiva entre diferentes algoritmos de regressão, reduzindo o viés na seleção manual do modelo.

Diversos algoritmos de regressão foram avaliados, incluindo Linear Regression, Ridge Regression, Lasso Regression, Elastic Net, Bayesian Ridge, Random Forest Regressor, Gradient Boosting Regressor e Extra Trees Regressor. A avaliação foi conduzida com base nas métricas de erro absoluto médio (MAE), erro quadrático médio (RMSE), erro percentual absoluto médio (MAPE) e coeficiente de determinação (R^2).

Entre os modelos avaliados, o Bayesian Ridge Regressor apresentou o melhor desempenho global, obtendo o menor MAE, baixos valores de RMSE e MAPE, além de elevado poder explicativo (R^2 0,91), sendo, portanto, selecionado como modelo final para a geração das previsões. Durante a etapa de inferência, são utilizadas variáveis de defasagem temporal (lags), construídas dinamicamente a partir do histórico de vendas de cada categoria.

3. Avaliação Experimental

3.1. Evals

Para validar a eficácia dos agentes em cenários reais, foi desenvolvida uma ferramenta de avaliação baseada em um corpus de 50 casos de teste com diferentes níveis de complexidade. O sistema utiliza métricas para medir a precisão da intenção e a utilidade da resposta final, contando com um sistema de tags dinâmicas que permite a execução seletiva de testes e a otimização da depuração. Ao final do processo, são gerados relatórios detalhados em múltiplos formatos (HTML, JSON e Markdown), facilitando a auditoria e a integração de dados.

3.2. Métricas Implementadas

Para a realização dos testes, a ferramenta de evels foi executada utilizando diferentes variantes da família de modelos de LLM, visando identificar o equilíbrio ideal entre latência, custo e precisão. A avaliação baseou-se em pilares fundamentais, cujas métricas foram calculadas da seguinte forma:

1. **Score de Interpretação (0-1):** Avalia a capacidade de compreensão da intenção do usuário. É composto pela confiança do modelo de LLM, clareza da intenção, identificação correta de entidades e pertinência das queries sugeridas.
2. **Score de Resposta (0-1):** Mensura a qualidade da saída final em linguagem natural. Analisa se a resposta é não-vazia, se responde diretamente à pergunta, a fluência em português, a correção das informações e a adequação do tamanho do texto.

Após a bateria de testes nos cenários, observou-se uma variação significativa de desempenho entre as versões. Abaixo estão os resultados médios obtidos pelos principais modelos avaliados:

Tabela 1. Tabela de avaliação dos modelos de LLM

Modelo Avaliado	Score Interpretação	Score SQL	Score Resposta	Média Geral
Gemini 1.5 Flash	0.88	0.90	0.85	0.87
Gemini 1.5 Pro	0.94	0.95	0.92	0.93
Gemini 2.5 Flash	0.97	0.98	0.96	0.97

O modelo Gemini 2.5 Flash demonstrou o melhor desempenho global. Ele superou as versões anteriores tanto na precisão da geração de SQL quanto na naturalidade da resposta final, consolidando-se como a escolha ideal para a implementação final da ferramenta.

3.3. Limitações Identificadas

A análise de desempenho revelou desafios importantes em quatro frentes principais. No que tange à precisão, observou-se que a ambiguidade em consultas vagas torna a

interpretação inconsistente, resultando em scores inferiores a 0,65, enquanto queries complexas, especificamente aquelas que exigem consulta entre mais de três lugares, apresentam uma taxa de erro aproximada de 25

Do ponto de vista arquitetural, o sistema opera com contexto limitado, não mantendo o estado entre sessões em produção, e o pipeline completo registra uma latência de processamento que oscila entre 2 e 3 segundos.

4. Conclusão e Trabalhos Futuros

Este trabalho apresentou o Commerce Intelligence, um sistema de análise de dados de e-commerce baseado em arquitetura multi-agentes de IA. A arquitetura de pipeline sequencial com agentes especializados demonstrou eficácia na interpretação de consultas e produção de respostas contextualizadas.

Os resultados experimentais validam a viabilidade da abordagem, especialmente para queries de baixa e média complexidade. A ferramenta de evals desenvolvida permite avaliação contínua e melhoria iterativa do sistema.